

# مشروع نظام المستشار الأكاديمي الذكي (Academic Advisor AI)

إعداد الفريق:  
1- البراء فهد صالح  
2- أمجد صادق  
3- عبدالله الحبيشي

التاريخ: 2026

# تعريف المشكلة والحل المقترن (The Problem & The Solution)



## المشكلة (The Challenge)

يواجه الوسط الأكاديمي تحديات في الكشف المبكر عن تعثر الطلاب. غالباً ما تُكتشف نقاط الضعف بعد تدني المعدل أو الرسوب.

- ضغط كبير على أعضاء هيئة التدريس في متابعة الأداء الفردي لأعداد كبيرة من الطلاب.



## الحل المقترن (The Solution)

نظام ذكي يعتمد على تحليل البيانات التاريخية والسلوكية للتنبؤ بالأداء وتقديم توصيات استباقية.

- المستفيدون: الطلاب، وأعضاء هيئة التدريس.

# متطلبات المشروع ونطاق العمل (Project Requirements & Scope)

## المتطلبات الوظيفية (Functional)

- نظام تسجيل دخول بصلاحيات محددة.
- لوحة تحكم (Dashboard) لعرض مستوى الطالب بيانيًّا.
- محرك توصيات ذكي يقترح مسارات دراسية بناءً على الميول والدرجات.
- نظام إنذار مبكر للطلاب المعرضين لخطر الت العثر الدراسي.

## المتطلبات التقنية (Technical)

- دقة عالية في التنبؤ .(Accuracy)
- واجهة مستخدم بديهية وسهلة التصفح.



# الهيكل التنظيمي والجدول الزمني (Organizational Structure)



## العضو الأول: مهندس بيانات

جمع وتنظيف البيانات، إعداد وإدارة قاعدة البيانات.



## العضو الثاني: مطور الذكاء الاصطناعي

بناء ونمذجة خوارزميات التنبؤ والتوصية.

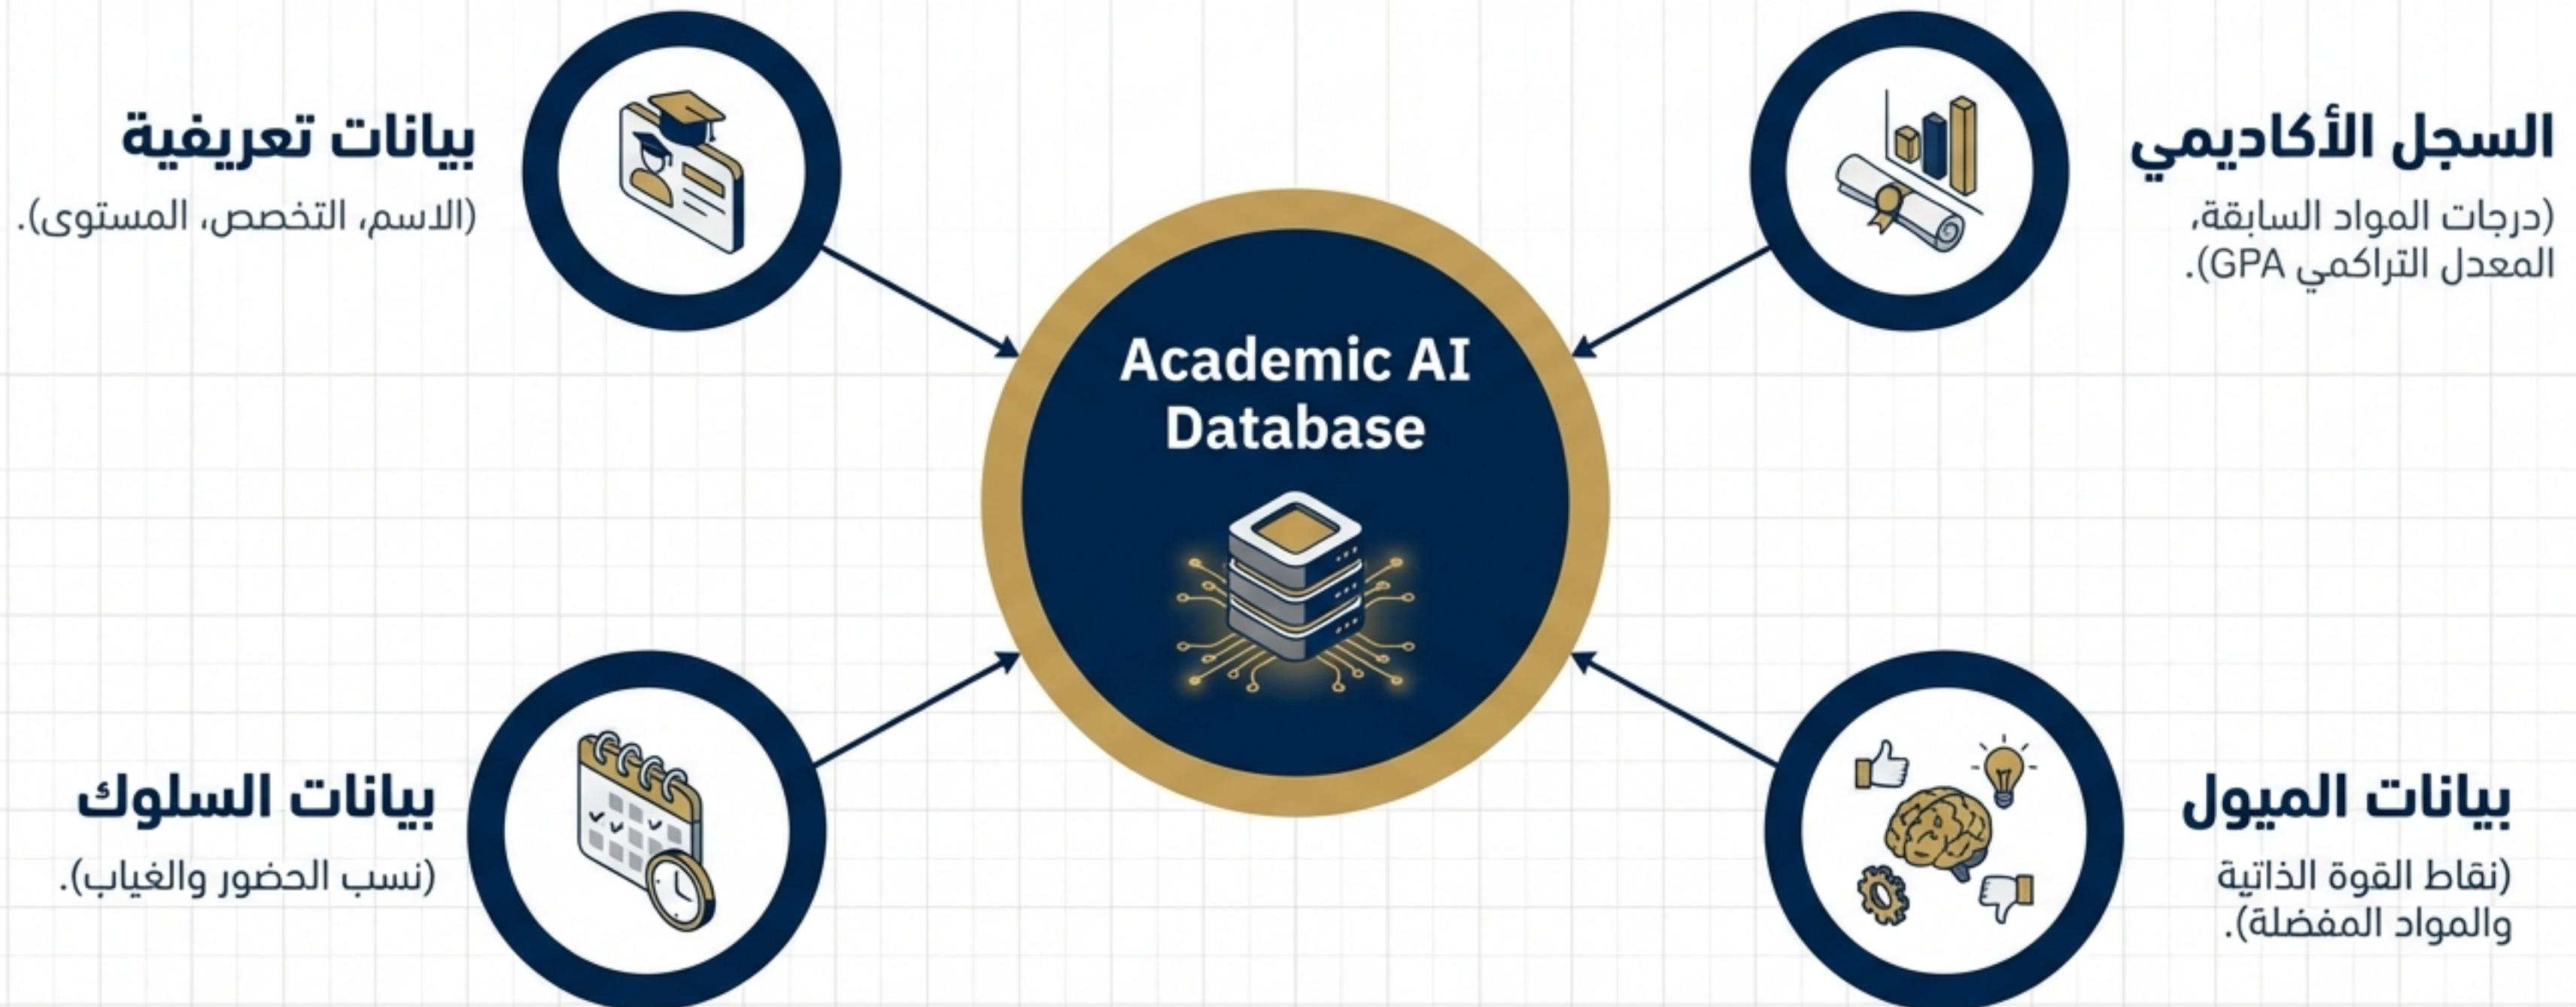


## العضو الثالث: مطور الواجهات

تصميم واجهة المستخدم وربط النظام برمجياً.

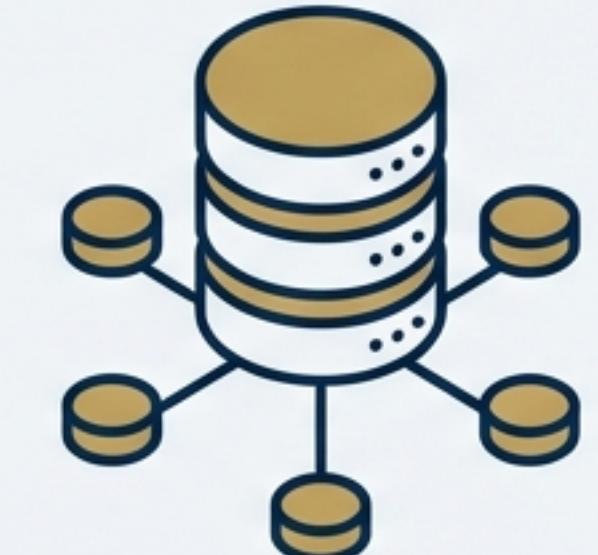
# مصادر البيانات (Data Sources)

يعتمد النظام على أربعة محاور أساسية من البيانات:



# تصميم قاعدة البيانات (Database Schema)

تم اعتماد هيكليّة ثلاثيّة مزنة لضمان سرعة الاستعلام ودقة الربط.



## Students (جدول الطلاب)

- البيانات الأساسية
- البريد الإلكتروني

## Academic\_Records (جدول السجلات)

- تفاصيل الدرجات
- نسب الحضور

## Recommendations (جدول التوصيات)

- المخرجات الذكية
- نتائج AI



# تنظيف وتجهيز البيانات (Data Preprocessing)

تمت معالجة بيانات 500 طالب عبر ثلاثة عمليات تقنية:



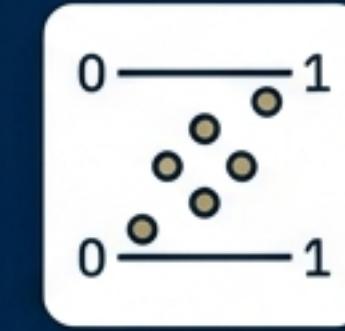
## معالجة القيم المفقودة

استخدام (Mean Imputation) لتعويض غياب بيانات الحضور بنسبة 5%.



## معالجة القيم المتطرفة

تطبيق تقنية (Clipping) لضمان بقاء الدرجات بين (0-100) والمعدل بين (4.0-0).



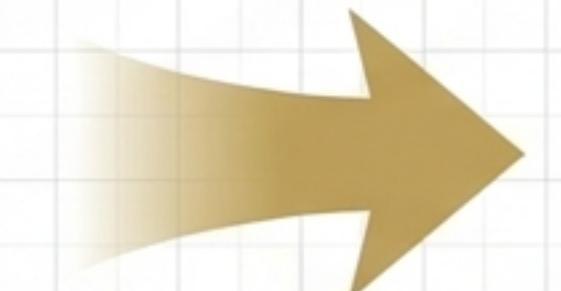
## تطبيع البيانات (Scaling)

استخدام (MinmaxScaler) لتوجيد نطاق جميع المدخلات بين (0 و 1).



## Input

original\_academic\_data.csv



## Output

cleaned\_academic\_data.csv



# اختيار المميزات والأنماط (Feature Selection)

ما هي العوامل المؤثرة على نجاح الطالب؟

## تأثير العوامل (Impact of Factors)

الارتباط (Correlation)

1. ساعات المذاكرة.  
(Study Hours)

0.85  
0.85%

2. نسبة الحضور.  
(Attendance)

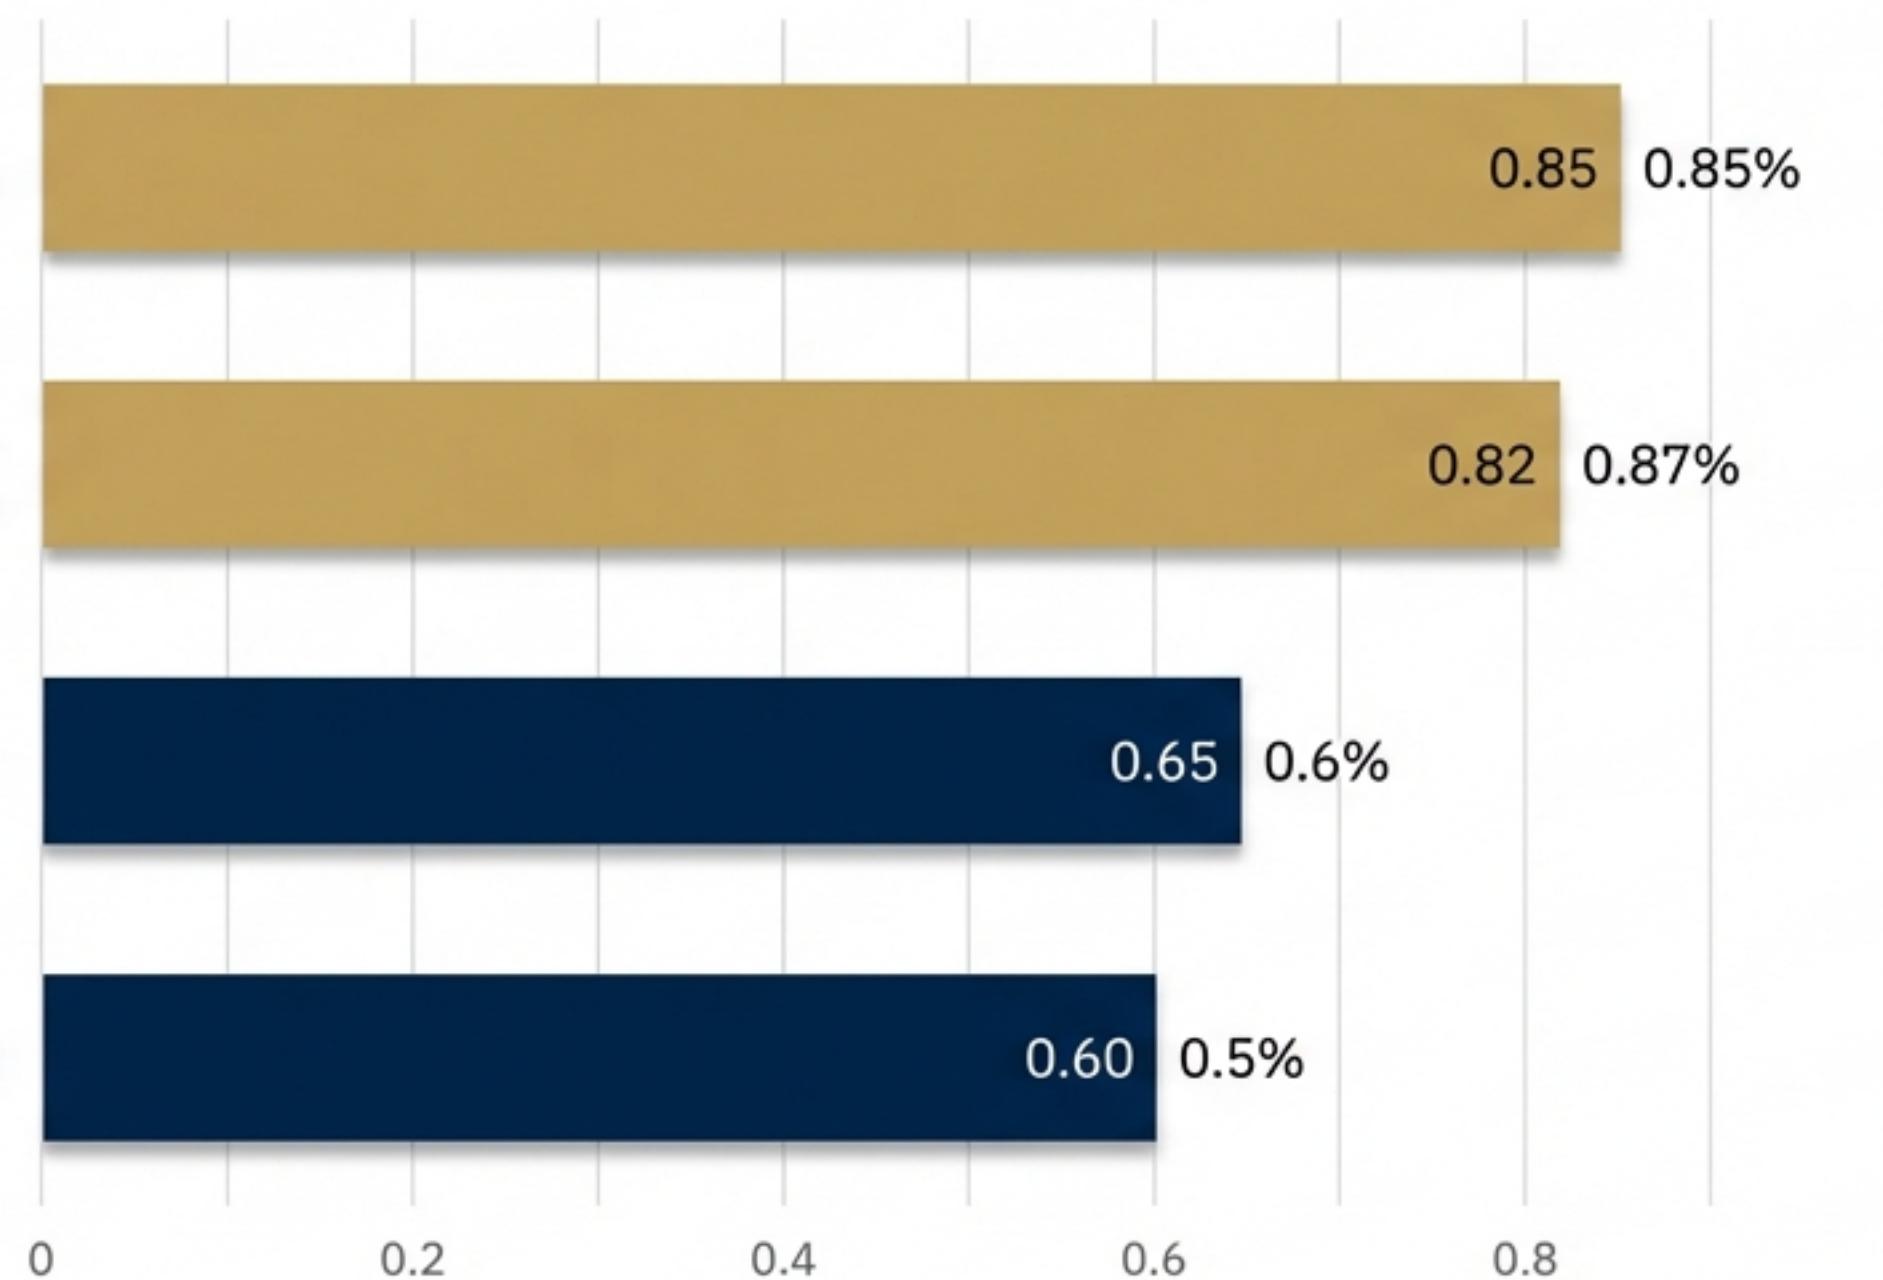
0.82  
0.87%

3. درجات الرياضيات.

0.65  
0.6%

4. درجات البرمجة.

0.60  
0.5%



## الرؤى المكتشفة (Insights)

- تبين أن ساعات المذاكرة ونسبة الحضور هما أقوى المؤشرات.

- وجود ارتباط طردي وثيق بين التميز في الرياضيات والتميز في البرمجة.

Source: Analysis based on student\_model.pkl data.

# النموذجية والتقييم النهائي (Modeling & Evaluation)

مقارنة أداء النماذج  
(Model Performance Comparison)

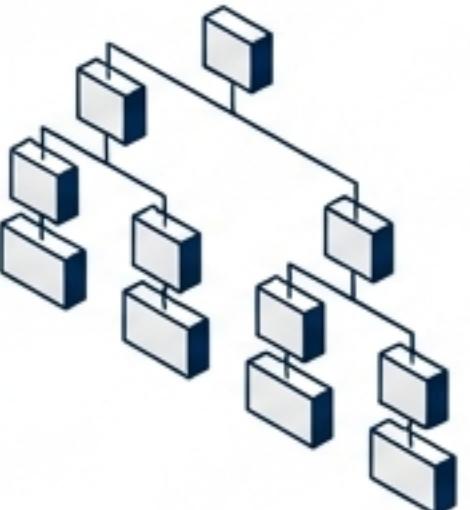
## الغابة العشوائية (Random Forest)



**0.98 R2 Score**

الأفضل في فهم العلاقات المعقدة.  
(The Best)

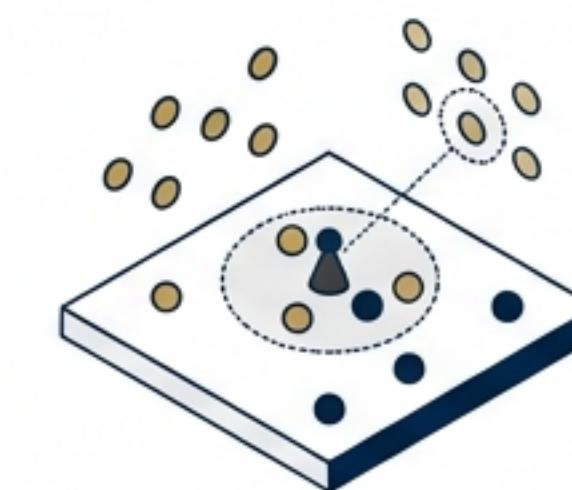
## Decision Tree



**0.95 R2 Score**

جيد جداً ولكنه معرض لـ Overfitting.

## KNN



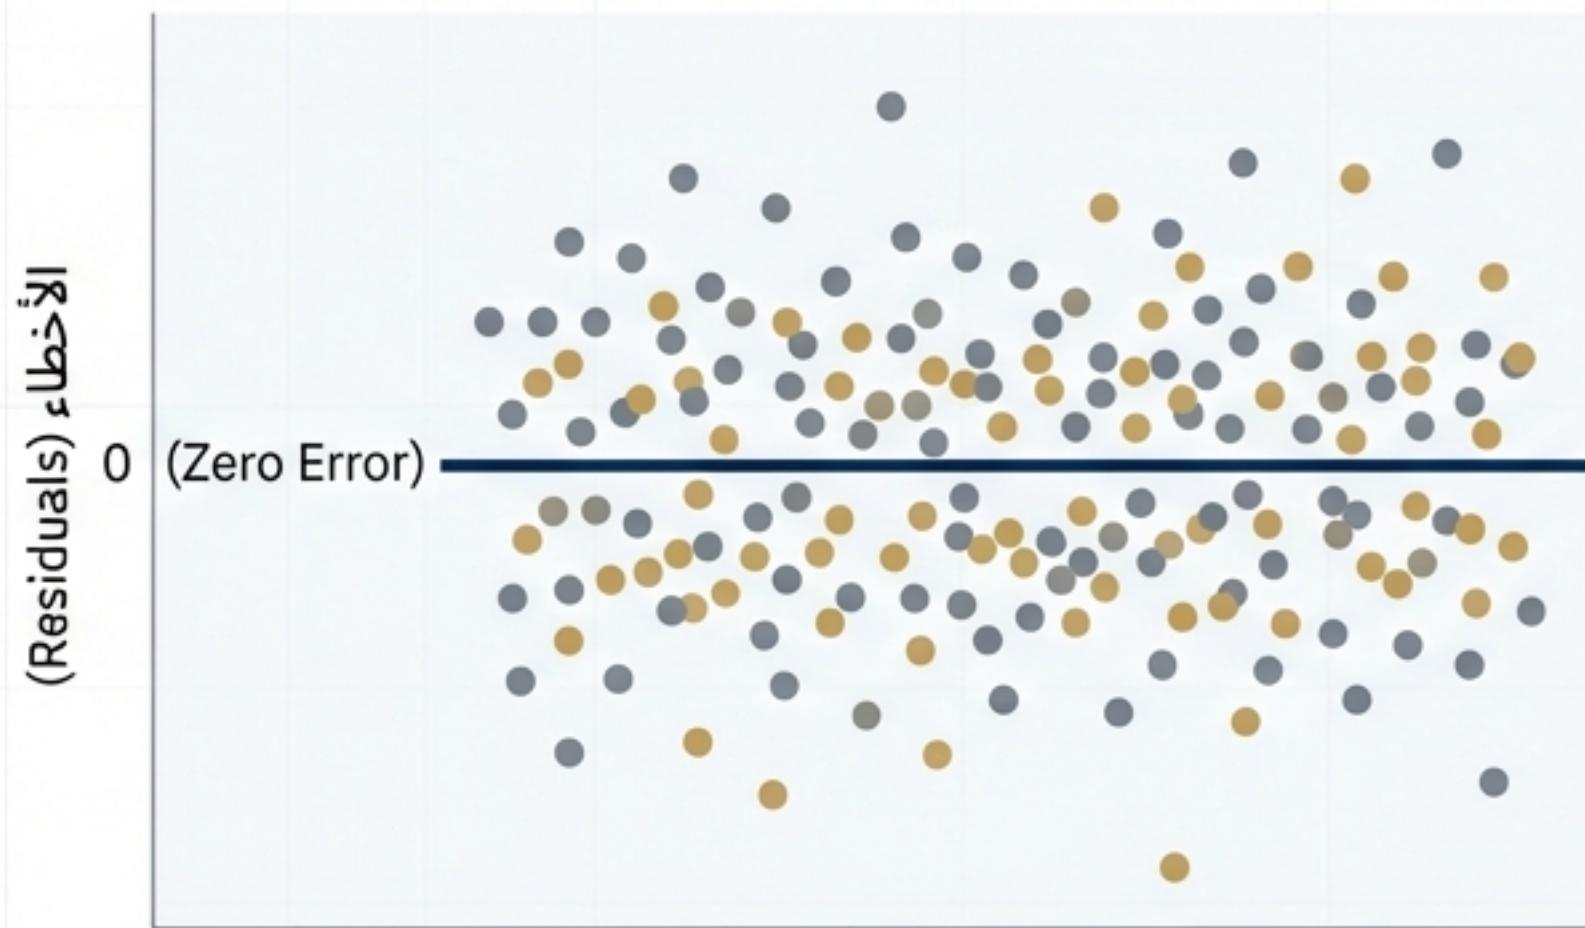
**متوسط**

مقبول ولكنه يتأثر بالضوضاء.

تم اختيار كنموذج نهائي نظراً لدقته العالية.

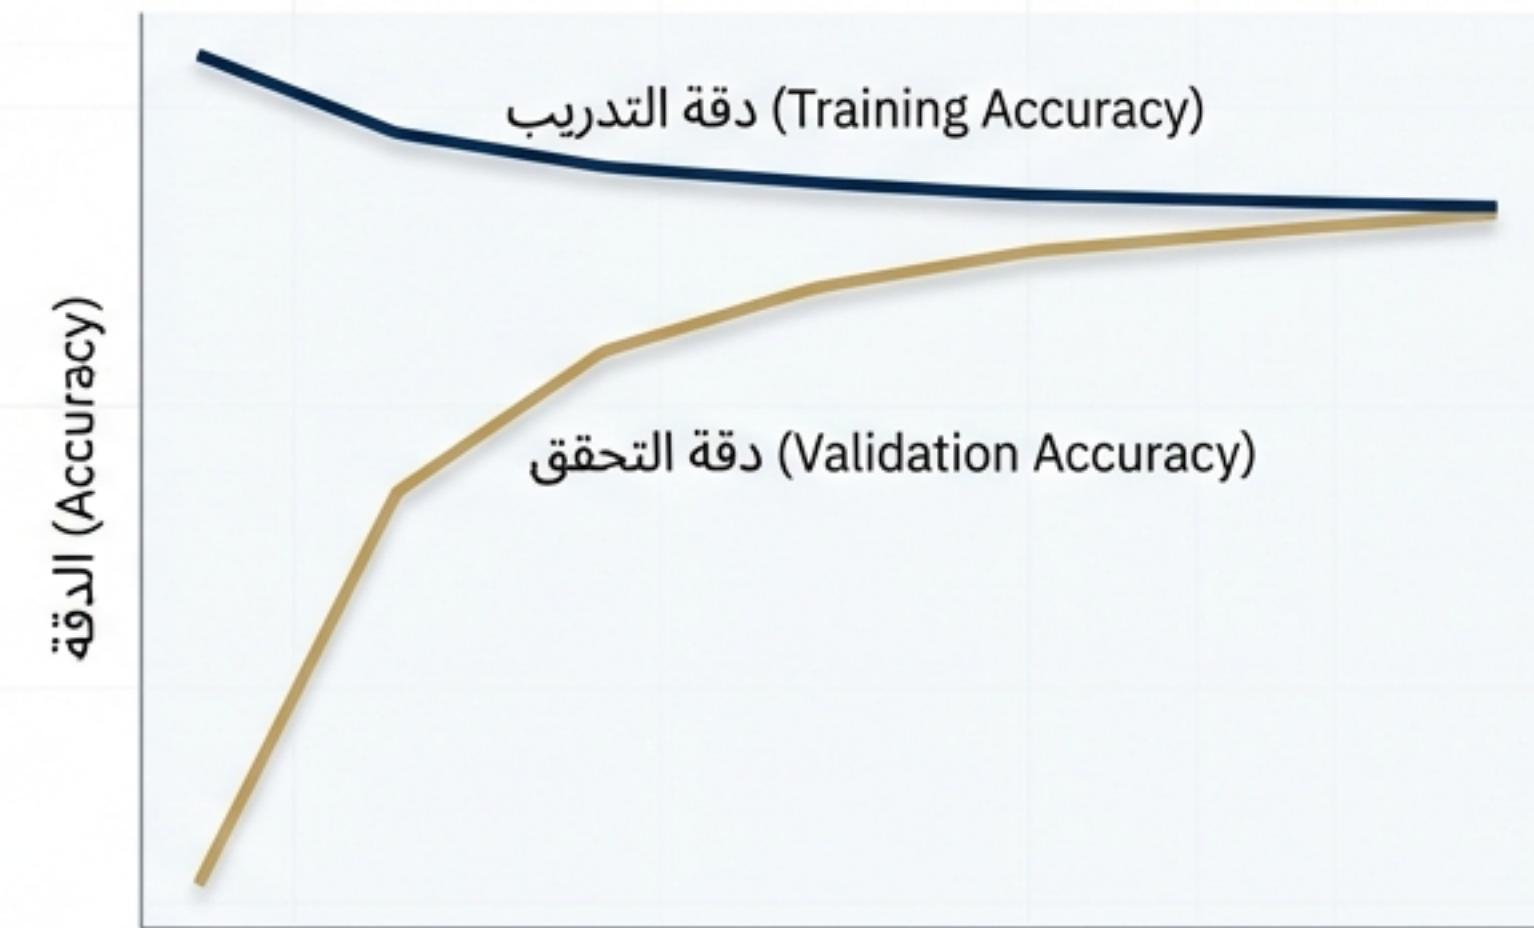
# التقييم النهائي للموديل المختار (Random Forest Performance)

## تحليل الأخطاء (Residual Plot)



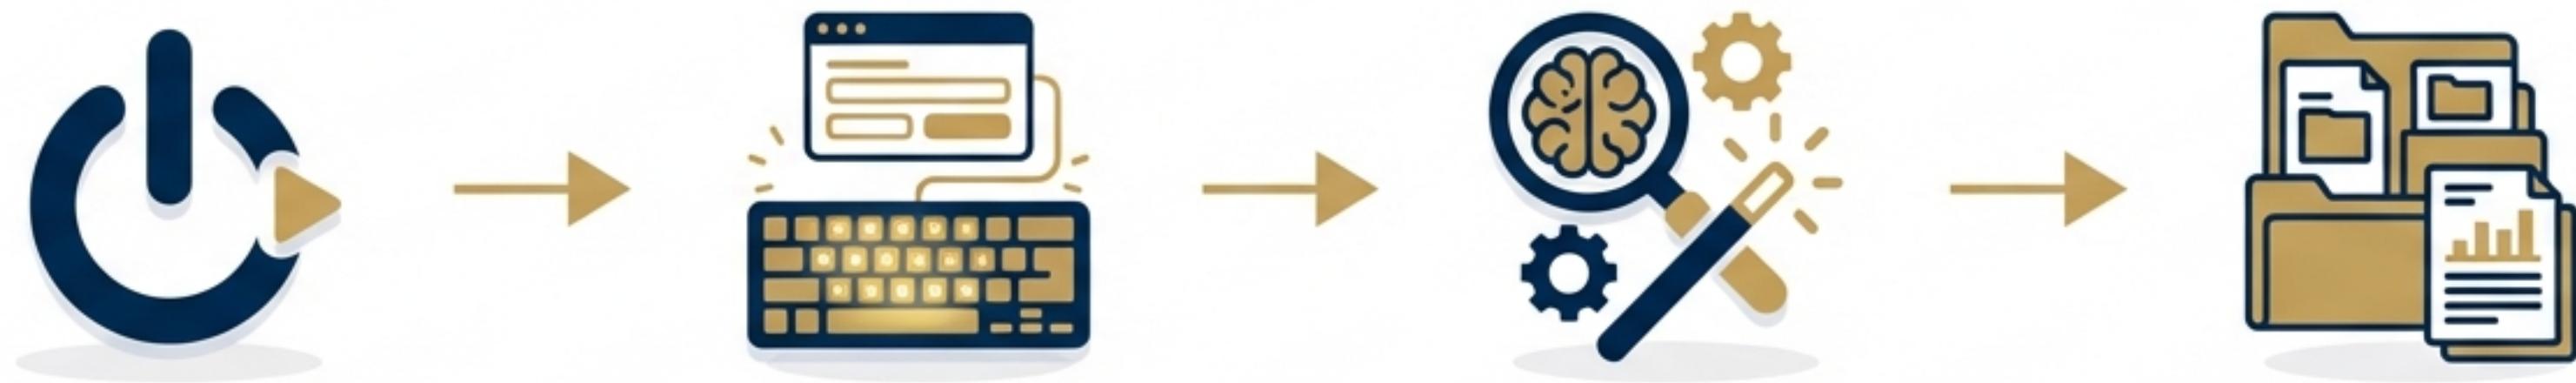
أظهر انتشاراً عشوائياً للأخطاء، مما يؤكد تجانس النموذج.

## منحنى التعلم (Learning Curve)



تقارب دقة التدريب والتحقق يثبت قدرة النموذج على التعميم  
. (Generalization).

# دليل الاستخدام والتشغيل (Operational Guide)



1. بدء النظام:  
التأكد من وجود ملف  
.student\_model.pkl.

2. إدخال البيانات: اسم  
الطالب، البريد،  
والدرجات.

3. الحصول على النتائج:  
الضغط على "تحليل  
الأداء".

4. إدارة السجلات:  
عرض الأرشيف أو التقرير  
المفصل.

# الخاتمة والرؤية المستقبلية (Conclusion)



بانتهاء هذه المراحل، تكون قد طورنا نظاماً ليس مجرد أداة حسابية، بل "مستشاراً رقمياً" قادرًا على تحويل الأرقام الصماء إلى رؤى أكاديمية واضحة.

تساهم هذه الأداة بشكل مباشر في نجاح العملية التعليمية ودعم اتخاذ القرار.